Diccionario de datos

Proyecto Petróleo · Producción de hidrocarburos líquidos por lote (PERUPETRO) y variables geográficas de los lotes

Repositorio: `adriansivina-droid/scraper-mef`, carpeta `HIDROCARBUROS/`. Este documento describe cada archivo que generan los notebooks, el significado de cada columna, sus unidades, los códigos que puede tomar y cómo se controló la calidad de los datos.

1. Qué son estos datos

La base principal es la **producción fiscalizada mensual de hidrocarburos líquidos por lote** que publica PERUPETRO S.A. en su Estadística Petrolera (anuales 1994–2025 y mensuales del año en curso). **Fiscalizada** significa medida en el punto de fiscalización del contrato: es el volumen sobre el que se calculan regalías, no la producción "de campo" estimada.

- **Cobertura:** enero 1994 – junio 2026 (33 años; 2026 con 6 meses). Un registro por lote, producto y mes.
- **Productos:** petróleo crudo, líquidos de gas natural (LGN) y condensado.
- **1994–2000** provienen de PDF escaneados y fueron **transcritos a mano** desde la imagen y validados contra los totales del PDF. **2001–2026** se extraen automáticamente del PDF digital.
- **Validación:** en los 33 años la suma de los lotes coincide con el total que imprime el PDF (diferencia 0). Además, el promedio diario calculado coincide con el publicado (p. ej. 1995: 121.762 bpd; 1997: 118.239 bpd).

2. Convenciones

Término	Tipo	Significado
`bbl`	unidad	Barril estadounidense = 42 galones = 158,987 litros. Todas las columnas BARRILES están en barriles.
`BPD / bpd`	unidad	Barriles por día calendario. Mensual: barriles del mes ÷ días del mes. Anual: barriles del año ÷ 365 (366 en bisiesto).
`MM bbl`	unidad	Millones de barriles (usado en resúmenes y en el mapa).
`Fechas`	texto	Formato **dd/mm/aaaa**. En los datos mensuales, FECHA es el día 01 del mes (01/03/2015 = marzo 2015).
`Codificación`	archivo	CSV en UTF-8 con BOM (se abre directo en Excel con tildes correctas), separador coma, punto decimal.
`Vacío / NaN`	—	Sin dato. En el ranking, vacío = el lote aún no existía; 0 = existía y no produjo (o no figura en el PDF ese año).

3. Archivos

Archivo	Rol	Contenido
`DATA/PP_produccion_lote_mes_<ini>-<fin>.csv`	Producción	Base principal: lote × producto × mes (§4).
`CONTROL/CONTROL PP produccion_lote_mes_<ini>-<fin>.csv`	Control	Una fila por año: de qué PDF salió y si cuadra con sus totales (§5).
`CONTROL/PP_CATALOGO_PDF.csv`	Control	Qué URL de PERUPETRO corresponde a cada PDF guardado (§6).
`DATA/PDF/PP_ANUAL_<año>.pdf, PP_MENSUAL_<año>_<mes>.pdf`	Fuente	Copia de los PDF originales de PERUPETRO.
`HIDROCARBUROS/transcripciones/PP_mensual_<año>_transcrito.csv`	Fuente	Tablas 1994–2000 transcritas desde los escaneos (§7).

Archivo	Rol	Contenido
DATA/PP_LOTES_GEO.csv	Geografía	Una fila por lote con departamento, cuenca, distancias, ANP y comunidades (§8).
DATA/MAPA/*.geojson, PP_mapa_lotes.html	Geografía	Polígonos y capas descargadas; mapa interactivo.
CONTROL/CONTROL PP mapa capas.csv / mapa descarga.csv	Control	Capas encontradas y descargadas para el mapa (§9).

4. Producción por lote y mes

Archivo PP_produccion_lote_mes_<ini>-<fin>.csv (notebook PP_Produccion_Lotes.ipynb). **Unidad de observación:** un lote, un producto, un mes. Clave única: AÑO + MES + LOTE + PRODUCTO.

Variable	Tipo / unidad	Descripción
AÑO	entero	Año calendario (1994–2026).
MES	entero 1–12	Mes calendario (1 = enero).
FECHA	texto dd/mm/aaaa	Primer día del mes; útil para ordenar y graficar series. Ej.: 01/06/2026.
ZONA	texto (código)	Zona geográfica de PERUPETRO: NOROESTE, ZOCALO (zócalo continental, en el mar), SELVA NORTE, SELVA CENTRAL, SELVA SUR. Se toma del encabezado de la tabla del PDF o, si no lo trae, de una tabla fija por lote.
DEPARTAMENTO	texto	Departamento (región) donde está el lote: el de mayor área según el mapa de lotes (PP_LOTES_GEO.csv). Si el lote no tiene polígono, se usa la zona (SELVA NORTE → LORETO) o queda vacío.
DEPARTAMENTO_FUENTE	texto (código)	MAPA (departamento por polígono del lote), ZONA (asignado por la zona) o vacío.
OPERADOR	texto	Empresa que opera el lote según el PDF de ese año (p. ej. OCCIDENTAL, PLUSPETROL, PETROTAL). Cambia en el tiempo: es el operador de ese mes, no el actual.
LOTE	texto (código)	Código homologado del contrato: sin la palabra "Lote", con guion estándar. Ej.: 192, 1-AB, 8, 95, Z-2B, 31-B/D, X, LOB/EA/LO. Los contratos temporales conservan el sufijo (T), p. ej. I(T).
LOTE_HISTORICO	texto (código)	Agrupa contratos que son el **mismo campo** a lo largo del tiempo, para series largas y rankings (ver §10). Ej.: 1-AB y 192 → 1-AB/192. Quita el sufijo (T).
LOTE_ORIGINAL	texto	Lote tal como aparece escrito en el PDF (p. ej. "31-C (LGN)", "Z - 2B"). Sirve para auditar.
PRODUCTO	texto (código)	PETROLEO (crudo), LGN (líquidos de gas natural: propano, butano, gasolina natural; Camisea, Aguaytía) o CONDENSADO. No sumar sin criterio: el petróleo y el LGN son mercados distintos.
BARRILES	número (bbl)	Producción fiscalizada del mes, en barriles.
BPD	número (bbl/día)	BARRILES ÷ días del mes, redondeado a 1 decimal. Permite comparar meses de distinta duración.
ESTADO_FILA	texto (código)	Calidad del registro: OK (leído y cuadra con el total del lote); IMPUTADO <MES> (ese único mes estaba en blanco en el PDF y se calculó como total anual − resto de meses); REVISAR (el lote no cuadra; no se presentó en la corrida completa); TRANSCRITO (1994–2000, desde la imagen).
FUENTE	texto	Archivo de origen: PP_ANUAL_<año>.pdf, PP_MENSUAL_<año>_<mes>.pdf o "TRANSCRIPCION PP_ANUAL_<año>.pdf p.N".

Cómo se eligió la fuente de cada año. Si existe el anual, se usa el anual (trae los 12 meses ya revisados). Para el año en curso, se usa la estadística mensual más reciente, que trae el acumulado del año. Por eso 2026 llega hasta junio y cambiará al volver a correr el notebook cuando PERUPETRO publique meses nuevos.

5. Control de la producción

Archivo `CONTROL PP produccion_lote_mes_<ini>-<fin>.csv`. Una fila por año (por archivo fuente). Es la evidencia de que los datos cuadran con el documento oficial.

Variable	Tipo / unidad	Descripción
`ARCHIVO`	texto	PDF (o PDF y página, en los transcritos) del que salieron los datos del año.
`TIPO`	texto (código)	ANUAL, MENSUAL (acumulado del año en curso) o TRANSCRITO.
`AÑO`	entero	Año de los datos.
`MESES`	entero	Meses cubiertos (12, o menos en el año en curso).
`LOTES`	entero	Filas lote-producto leídas en la tabla del PDF.
`FILAS_IMPUTADAS`	entero	Lotes con un mes completado por diferencia (ver ESTADO_FILA). En la corrida completa: 1 (año 2021).
`FILAS_REVISAR`	entero	Lotes cuya suma de meses no coincide con su total. Debe ser 0.
`DIF_MAX_TOTAL`	número (bbl)	Máxima diferencia mensual entre la suma de los lotes y el TOTAL/SUB-TOTAL impreso en el PDF. **0 = cuadra exacto.** Es el control principal.
`BARRILES_PETROLEO / _LGN / _CONDENSADO`	número (bbl)	Total del año por producto (suma de lotes).
`DIF_MAX_PETROLEO / _LGN / _CONDENSADO`	número (bbl)	Igual que DIF_MAX_TOTAL pero contra el subtotal de cada producto. Vacío cuando el PDF no imprime subtotal por producto (anuales antiguos, 2001–2006).
`ESTADO`	texto (código)	OK; OK (transcrito); REVISAR (no cuadra); SIN TABLA; ESCANEADO / FORMATO ANTIGUO (PDF sin tabla legible, cubierto por transcripción); ERROR DE DESCARGA.
`FECHA_EXTRACCION`	texto dd/mm/aaaa	Día en que se corrió el notebook.

6. Catálogo de PDF

Variable	Tipo / unidad	Descripción
`URL`	texto	Dirección del PDF en perupetro.com.pe.
`ARCHIVO`	texto	Nombre con que se guardó en DATA/PDF (PP_ANUAL_<año>.pdf o PP_MENSUAL_<año>_<mes>.pdf). Permite no volver a descargar lo ya guardado.

7. Transcripciones 1994–2000

Archivos `PP_mensual_<año>_transcrito.csv`, en formato ancho (un lote por fila, un mes por columna), tal como la tabla del PDF. El notebook los convierte al formato de §4.

Variable	Tipo / unidad	Descripción
`ANIO`	entero	Año.
`PRODUCTO, OPERADOR, LOTE_ORIGINAL, LOTE`	texto	Igual que en §4. OPERADOR conserva el nombre del PDF de esa época (p. ej. VEGSA, MPOG, PETROPERU / PLUSPETROL).
`ENE … DIC`	número (bbl)	Producción de cada mes.

Variable	Tipo / unidad	Descripción
TOTAL	número (bbl)	Total anual del lote impreso en el PDF (se verifica que sea la suma de los meses).
FUENTE	texto	PDF y página de la tabla (p. ej. PP_ANUAL_1995.pdf p.18).
fila TOTAL	—	Última fila: totales del PDF por mes, usados para validar.

Validación de cada año transcrito: (1) cada lote suma su total; (2) cada mes suma el TOTAL impreso; (3) el gran total coincide con la tabla "por contratista" del mismo PDF. Las celdas que no cuadran se releen con más aumento; en 1995 se usó además un cuadro de control de la p.17 con las mismas cifras en otra tipografía.

8. Variables geográficas por lote

Archivo PP_LOTES_GEO.csv (notebook PP_Mapa_Lotes.ipynb). Una fila por lote. **Estado:** notebook listo y probado con datos simulados; pendiente la primera corrida con el mapa real de PERUPETRO.

Variable	Tipo / unidad	Descripción
FECHA_EXTRACCION	texto dd/mm/aaaa	Día de la corrida.
LOTE	texto (código)	Mismo código que en §4, para unir ambas tablas.
GEOMETRIA_DE	texto	Lote(s) del mapa cuyo polígono se usó. Igual a LOTE, salvo equivalencias: lote histórico (1-AB → 192; Z-69 → Z-2B), contrato temporal sin sufijo (I(T) → I) o unión de partes (31-B/D → 31-B+31-D; VII/VI → VII+VI).
LOTE_MAPA, OPERADOR_MAPA, ESTADO_MAPA, CAPA	texto	Nombre, operador y estado del lote según el mapa, y capa de origen.
DEPARTAMENTO	texto	Departamento con mayor parte del área del lote.
DEPARTAMENTO_PCT	% (0–100)	Porcentaje del área del lote en ese departamento.
DEPARTAMENTO_DETALLE	texto	Reparto completo, p. ej. "LORETO 67,7%; UCAYALI 32,3%".
DEPARTAMENTO_N	entero	Número de departamentos que toca el lote.
ZOCALO	SI / NO	SI para lotes mayormente en el mar (menos del 50 % de su área en tierra); se asignan al departamento costero más cercano o al de su parte en tierra.
CUENCA, CUENCA_PCT	texto, %	Cuenca sedimentaria (Marañón, Ucayali, Talara, ...) y % del lote en ella.
AREA_KM2	número (km²)	Superficie del lote (proyección equivalente de Sudamérica, ESRI:102033).
LAT, LON	grados decimales	Punto interior del lote (WGS84).
DIST_OLEODUCTO_KM	número (km)	Distancia mínima del borde del lote al Oleoducto Norperuano; 0 si lo cruza.
DIST_IQUITOS_KM	número (km)	Distancia mínima del lote a Iquitos.
DIST_RIO_GRANDE_KM	número (km)	Distancia al río más cercano con caudal medio ≥ umbral elegido (300 m³/s por defecto; HydroRIVERS, caudal modelado). Aproxima el acceso fluvial; no es una medida oficial de navegabilidad.
DIST_RIO_100_KM / _300_KM / _1000_KM	número (km)	Misma distancia con umbrales de 100, 300 y 1.000 m³/s (análisis de sensibilidad).
RIO_CERCANO	texto	Nombre del río grande más cercano (ríos con nombre de OpenStreetMap que coinciden con un tramo de HydroRIVERS ≥ umbral; respaldo Natural Earth).
ANP_PCT, ANP_DETALLE	%, texto	Porcentaje del lote dentro de Áreas Naturales Protegidas y cuáles.

Variable	Tipo / unidad	Descripción
CCNN_DENTRO_N, CCNN_5KM_N, CCNN_DENTRO	entero, texto	Comunidades nativas dentro del lote, a menos de 5 km, y sus nombres.
PETROLEO_ACUM_MMBBL	número (MM bbl)	Petróleo acumulado del lote en la base de §4.
PETROLEO_ACUM_CAMPO_MMBBL	número (MM bbl)	Acumulado de todos los contratos que comparten el polígono (p. ej. 1-AB + 192).

Fuentes del mapa: visor "Mapa de Lotes de contrato" de PERUPETRO (ArcGIS Online); límites departamentales geoBoundaries (basados en INEI); HydroRIVERS y Natural Earth (ríos); SERNANP u OpenStreetMap (ANP); servicios públicos de comunidades nativas; oleoducto desde PERUPETRO u OpenStreetMap. **Primera corrida (11/10/2026):** el servidor de PERUPETRO (gismaptemp) no responde; se usaron los lotes de enero 2019 publicados por INGEMMET, el Oleoducto Norperuano de WWF Perú, ANP y comunidades nativas de servicios públicos de ArcGIS Online (ver CONTROL PP mapa capas.csv).

9. Control del mapa

Variable	Tipo / unidad	Descripción
N, CAPA, GRUPO	texto	Número, nombre y grupo de la capa encontrada.
URL, TIPO, GEOMETRIA	texto	Servicio ArcGIS, tipo de capa y geometría (polígono, línea, punto).
FUENTE, TEMA	texto	PERUPETRO u otro servicio; tema (LOTES, ANP, CCNN, OLEODUCTO).
ERROR	texto	Motivo si la capa no respondió (p. ej. requiere inicio de sesión).
ENTIDADES, ESTADO	entero, texto	En el control de descarga: cuántos elementos llegaron y si fue OK; incluye la fila "LOTES SIN POLIGONO" con los lotes con producción sin ubicar.

10. Lotes históricos y equivalencias

Código en los datos	LOTE_HISTORICO	Explicación
1-AB → 192	1-AB/192	Mismo campo (Loreto). El contrato 1-AB terminó el 29/08/2015; desde el 30/08/2015 es el Lote 192.
Z-2B → Z-69	Z-2B/Z-69	Zócalo (Piura/Tumbes). Pasó a PetroPerú como Z-69 (fecha a confirmar con el PDF de 2023).
31-B, 31-D → 31-B/D	31-B/D	Maple: Maquía (31-B) y Agua Caliente (31-D). El PDF los separa hasta 2000 y los une desde 2001.
LOB/EA/LO	LOB/EA/LO	Lobitos, El Alto y Los Órganos (OXY/Bridas, Noroeste). Desde el 24/07/1996 se integró al Lote X, salvo los yacimientos Folche y Cruz, que pasaron al VI. Se mantiene separado.
Sufijo (T)	sin sufijo	Contrato temporal (p. ej. I(T), VI(T)): mismo lote, se agrupa con el lote base.

11. Cómo usar los datos (recomendaciones)

- **Totales anuales:** sumar BARRILES por AÑO; para comparar años con distinto número de meses usar BPD promedio.
- **Series de un campo:** agrupar por LOTE_HISTORICO, no por LOTE.
- **Petróleo vs. LGN:** filtrar PRODUCTO; el LGN (Camisea desde 2004) supera al petróleo desde 2009 y distorsiona los totales de "líquidos".
- **Loreto:** filtrar DEPARTAMENTO = "LORETO" (incluye 31-B Maquía y 31-E, que el PDF ubica en Selva Central).
- **Año en curso:** es parcial; no comparar su total con años completos.

- **Operador:** es el del momento; para análisis por empresa usar OPERADOR del mes, no el actual.
- **Calidad:** antes de publicar, revisar que el CONTROL tenga ESTADO OK / OK (transcrito) en todos los años usados.

12. Limitaciones conocidas

- Los polígonos de lotes son de enero 2019 (INGEMMET): los lotes firmados después no tienen polígono y su DEPARTAMENTO sale de la zona.
- La fecha exacta del paso Z-2B → Z-69 está por confirmar.
- 1994–2000 provienen de escaneos: transcritos y validados al barril, pero sin capa digital original.
- Si PERUPETRO cambia el formato de sus PDF o de su página, el CONTROL lo mostrará como SIN TABLA o REVISAR (no como datos erróneos).