# Diccionario de datos

Proyecto Petróleo · Producción de hidrocarburos líquidos por lote (PERUPETRO) y variables geográficas de los lotes

Repositorio: `adriansivina-droid/scraper-mef`, carpeta `HIDROCARBUROS/`. Este documento describe cada archivo que generan los notebooks, el significado de cada columna, sus unidades, los códigos que puede tomar y cómo se controló la calidad de los datos.

## 1. Qué son estos datos

La base principal es la **producción fiscalizada mensual de hidrocarburos líquidos por lote** que publica PERUPETRO S.A. en su Estadística Petrolera (anuales 1994–2025 y mensuales del año en curso). **Fiscalizada** significa medida en el punto de fiscalización del contrato: es el volumen sobre el que se calculan regalías, no la producción "de campo" estimada.

- **Cobertura:** enero 1994 – junio 2026 (33 años; 2026 con 6 meses). Un registro por lote, producto y mes.
- **Productos:** petróleo crudo, líquidos de gas natural (LGN) y condensado.
- **1994–2000** provienen de PDF escaneados y fueron **transcritos a mano** desde la imagen y validados contra los totales del PDF. **2001–2026** se extraen automáticamente del PDF digital.
- **Validación:** en los 33 años la suma de los lotes coincide con el total que imprime el PDF (diferencia 0). Además, el promedio diario calculado coincide con el publicado (p. ej. 1995: 121.762 bpd; 1997: 118.239 bpd).

## 2. Convenciones

| Término | Tipo | Significado |
|---|---|---|
| `bbl` | unidad | Barril estadounidense = 42 galones = 158,987 litros. Todas las columnas BARRILES están en barriles. |
| `BPD / bpd` | unidad | Barriles por día calendario. Mensual: barriles del mes ÷ días del mes. Anual: barriles del año ÷ 365 (366 en bisiesto). |
| `MM bbl` | unidad | Millones de barriles (usado en resúmenes y en el mapa). |
| `MPC / MMPC / BCF` | unidad (gas) | Gas natural: MPC = miles de pies cúbicos (Mcf); MMPC = millones; BCF = miles de millones. MMPCD = millones de pies cúbicos por día. |
| `Fechas` | texto | Formato **dd/mm/aaaa**. En los datos mensuales, FECHA es el día 01 del mes (01/03/2015 = marzo 2015). |
| `Codificación` | archivo | CSV en UTF-8 con BOM (se abre directo en Excel con tildes correctas), separador coma, punto decimal. |
| `Vacío / NaN` | — | Sin dato. En el ranking, vacío = el lote aún no existía; 0 = existía y no produjo (o no figura en el PDF ese año). |

## 3. Archivos

| Archivo | Rol | Contenido |
|---|---|---|
| `DATA/PP_produccion_lote_mes_<ini>-<fin>.csv` | Producción | Base principal: lote × producto × mes (§4). |
| `DATA/PP_produccion_gas_lote_mes_<ini>-<fin>.csv` | Producción | Gas natural fiscalizado: lote × mes, en MPC, 1994–hoy (§4b). |
| `DATA/PP_produccion_diaria.csv` | Producción | Producción fiscalizada diaria por lote: líquidos (bbl) y gas (Mcf, MMBtu) (§4c). |

| Archivo | Rol | Contenido |
|---|---|---|
| DATA/PP_pozos_perforados_lote_anio.csv | Actividad | Pozos perforados por lote, año y tipo (exploratorio, confirmatorio, desarrollo), 1995–hoy (§4d). |
| DATA/PP_regalias_lote_anio.csv | Fiscal | Regalías (ingresos al fisco) por lote e hidrocarburo, US$, 2001–hoy (§4d). |
| DATA/PP_canon_departamento_anio.csv | Fiscal | Canon y sobrecanon petrolero por departamento, millones de soles, 1993–hoy (§4d). |
| DATA/PP_precio_canasta_lote_mes.csv | Precios | Precio de la canasta de líquidos por lote y mes, US$/bbl, 2001–hoy (§4d). |
| DATA/PP_valor_produccion_lote_mes.csv | Producción | Valor de la producción de líquidos = barriles × precio de canasta (§4d). |
| DATA/PP_canon_departamento_mes.csv | Fiscal | Canon y sobrecanon por departamento y mes, de las estadísticas mensuales (2025–hoy, se acumula) (§4d). |
| DATA/PP_ingresos_estado_mes.csv | Fiscal | Ingresos para el Estado por mes y tipo de contrato, total nacional (§4d). |
| DATA/PP_contratos.csv | Empresas | Contratos vigentes y terminados por edición: empresas socias con su %, suscripción, término y área, 2004–hoy (§4d). |
| DATA/CANON_EXCEL/PP_CANON_*.xlsx | Fuente | Excel de canon de PERUPETRO: Determinación por año, Distribución y Municipalidades por departamento (§4e). |
| DATA/PP_canon_lote_mes.csv | Fiscal | Canon y sobrecanon por lote y mes (US$) y la parte de cada departamento, de la Determinación (§4e). |
| DATA/PP_canon_distribucion_mes.csv | Fiscal | Canon por departamento, mes y beneficiario (S/), 1993–hoy, de la Distribución (§4e). |
| DATA/PP_canon_municipal_mes.csv | Fiscal | Canon por municipalidad provincial y distrital y mes (S/): año en curso y 1993–2002 (§4e). |
| CONTROL/CONTROL PP canon_excel.csv · canon_excel_lectura.csv | Control | Descarga de los Excel de canon y control de su lectura y cruces (§4e). |
| DATA/PP_operadores_lote.csv | Empresas | Quién operó cada lote y en qué años, según la producción fiscalizada (lo arma el mapa, §8b). |
| CONTROL/CONTROL PP tablas_adicionales.csv | Control | Suma de lotes vs total del PDF de cada tabla adicional (§4d). |
| CONTROL/CONTROL PP produccion_lote_mes_<ini>-<fin>.csv | Control | Una fila por año: de qué PDF salió y si cuadra con sus totales (§5). |
| CONTROL/PP_CATALOGO_PDF.csv | Control | Qué URL de PERUPETRO corresponde a cada PDF guardado (§6). |
| DATA/PDF/PP_ANUAL_<año>.pdf, PP_MENSUAL_<año>_<mes>.pdf | Fuente | Copia de los PDF originales de PERUPETRO. |
| HIDROCARBUROS/transcripciones/PP_mensual_<año>_transcrito.csv | Fuente | Tablas 1994–2000 transcritas desde los escaneos (§7). |
| DATA/PP_LOTES_GEO.csv | Geografía | Una fila por lote con departamento, cuenca, distancias, ANP y comunidades (§8). |
| DATA/PP_LOTES_INDICADORES.csv | Producción | Una fila por lote: estado, pico, producción actual, declinación, paralizaciones y operadores (§8b). |
| DATA/MAPA/*.geojson, PP_mapa_lotes.html | Geografía | Polígonos y capas descargadas; mapa interactivo. |
| CONTROL/CONTROL PP mapa capas.csv / mapa descarga.csv | Control | Capas encontradas y descargadas para el mapa (§9). |

## 4. Producción por lote y mes

Archivo PP_produccion_lote_mes_<ini>-<fin>.csv (notebook PP_Produccion_Lotes.ipynb). **Unidad de observación:** un lote, un producto, un mes. Clave única: AÑO + MES + LOTE + PRODUCTO.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| AÑO | entero | Año calendario (1994–2026). |
| MES | entero 1–12 | Mes calendario (1 = enero). |
| FECHA | texto dd/mm/aaaa | Primer día del mes; útil para ordenar y graficar series. Ej.: 01/06/2026. |
| ZONA | texto (código) | Zona geográfica de PERUPETRO: NOROESTE, ZOCALO (zócalo continental, en el mar), SELVA NORTE, SELVA CENTRAL, SELVA SUR. Se toma del encabezado de la tabla del PDF o, si no lo trae, de una tabla fija por lote. |
| DEPARTAMENTO | texto | Departamento (región) donde está el lote: el de mayor área según el mapa de lotes (PP_L0TES_GE0.csv). Si el lote no tiene polígono, se usa la zona (SELVA NORTE → LORETO) o queda vacío. |
| DEPARTAMENTO_FUENTE | texto (código) | MAPA (departamento por polígono del lote), ZONA (asignado por la zona) o vacío. |
| OPERADOR | texto | Empresa que opera el lote según el PDF de ese año (p. ej. OCCIDENTAL, PLUSPETROL, PETROTAL), con el nombre homologado: se corrigen nombres cortados y erratas del PDF (PLUSPETRO → PLUSPETROL, UPLAND OIL AND → UPLAND OIL AND GAS, PETROLERA MONTERRRICO → PETROLERA MONTERRICO, G.M.P. → GMP…). Cambia en el tiempo: es el operador de ese mes, no el actual. |
| OPERADOR_ORIGINAL | texto | Nombre tal como aparece en el PDF, para auditar la homologación. |
| LOTE | texto (código) | Código homologado del contrato: sin la palabra "Lote", con guion estándar. Ej.: 192, 1-AB, 8, 95, Z-2B, 31-B/D, X, LOB/EA/LO. Los contratos temporales conservan el sufijo (T), p. ej. I(T). |
| LOTE_HISTORICO | texto (código) | Agrupa contratos que son el **mismo campo** a lo largo del tiempo, para series largas y rankings (ver §10). Ej.: 1-AB y 192 → 1-AB/192. Quita el sufijo (T). |
| LOTE_ORIGINAL | texto | Lote tal como aparece escrito en el PDF (p. ej. "31-C ( LGN )", "Z - 2B"). Sirve para auditar. |
| PRODUCTO | texto (código) | PETROLEO (crudo), LGN (líquidos de gas natural: propano, butano, gasolina natural; Camisea, Aguaytía) o CONDENSADO. No sumar sin criterio: el petróleo y el LGN son mercados distintos. |
| BARRILES | número (bbl) | Producción fiscalizada del mes, en barriles. |
| BPD | número (bbl/día) | BARRILES ÷ días del mes, redondeado a 1 decimal. Permite comparar meses de distinta duración. |
| ESTADO_FILA | texto (código) | Calidad del registro: OK (leído y cuadra con el total del lote); IMPUTADO <MES> (ese único mes estaba en blanco en el PDF y se calculó como total anual − resto de meses); REVISAR (el lote no cuadra; no se presentó en la corrida completa); TRANSCRITO (1994–2000, desde la imagen). |
| FUENTE | texto | Archivo de origen: PP_ANUAL_<año>.pdf, PP_MENSUAL_<año>_<mes>.pdf o "TRANSCRIPCION PP_ANUAL_<año>.pdf p.N". |

**Cómo se eligió la fuente de cada año.** Si existe el anual, se usa el anual (trae los 12 meses ya revisados). Para el año en curso, se usa la estadística mensual más reciente, que trae el acumulado del año. Por eso 2026 llega hasta junio y cambiará al volver a correr el notebook cuando PERUPETRO publique meses nuevos.

## 4b. Gas natural por lote y mes

Archivo PP_produccion_gas_lote_mes_<ini>-<fin>.csv, del mismo notebook y de los mismos PDF: tabla «Producción fiscalizada mensual de gas natural (MPC)». Se descartan la versión en MMBTU, la producción «de campo» y los balances. **Cobertura:** 1994–hoy. 2001 en adelante se extrae del PDF digital; 1994–2000 se transcribió a mano desde los escaneos (transcripciones/PP_gas_mensual_<año>_transcrito.csv) y cuadra exacto con los totales del PDF. Clave única: AÑO + MES + LOTE.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| AÑO, MES, FECHA, ZONA, DEPARTAMENTO, DEPARTAMENTO_FUENTE | — | Igual que en §4. |
| OPERADOR, OPERADOR_ORIGINAL, LOTE, LOTE_HISTORICO, LOTE_ORIGINAL | — | Igual que en §4. |
| PRODUCTO | texto | Siempre GAS NATURAL. |
| MPC | número (MPC) | Gas natural fiscalizado del mes, en miles de pies cúbicos. Camisea (lotes 88, 56 y 57) concentra ~95 %. |
| MMPCD | número (MMPC/día) | MPC ÷ días del mes ÷ 1.000 (millones de pies cúbicos por día), 3 decimales. |
| ESTADO_FILA | texto (código) | OK, REVISAR o TRANSCRITO (1994–2000). En gas el PDF trae decimales y redondea cada celda: se acepta hasta 6 MPC de diferencia entre la suma de los meses y el total del lote. |
| FUENTE | texto | PDF de origen. |

En el archivo de control se agregan LOTES_GAS, GAS_MPC (total del año), DIF_MAX_GAS (máxima diferencia mensual contra el TOTAL del PDF; tolerancia 12 MPC por redondeo) y ESTADO_GAS (OK, OK (transcrito), REVISAR o SIN TABLA).

## 4c. Producción diaria por lote

Archivo PP_produccion_diaria.csv (notebook PP_Produccion_Lotes.ipynb, sección «Producción diaria»), de los reportes diarios de la página «Producción Diaria» de PERUPETRO. Se acumula: cada corrida reemplaza los meses que vuelve a leer. Clave única: FECHA + UNIDAD + PRODUCTO + LOTE + OPERADOR.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| FECHA, AÑO, MES, DIA | fecha dd/mm/aaaa, enteros | Día de la producción. |
| FLUIDO | texto | LIQUIDOS o GAS NATURAL. |
| PRODUCTO | texto (código) | PETROLEO Y CONDENSADO, LGN o GAS NATURAL. |
| UNIDAD | texto (código) | BBL (barriles), MCF (miles de pies cúbicos), MMBTU (millones de BTU, contenido energético del gas) o M3 (metros cúbicos; 1 Mcf = 28,3168 m3). |
| OPERADOR, LOTE_ORIGINAL, LOTE | texto | Como figuran en el encabezado del reporte; LOTE homologado (X. → X, 192_LIC → 192). |
| VALOR | número | Producción fiscalizada del día en la UNIDAD indicada. En líquidos, algunos lotes se fiscalizan por lotes (entregas), por eso hay días en 0 y días con valores altos: para promedios usar el mes. |
| FUENTE, DEPARTAMENTO | texto | PDF guardado en DATA/PDF_DIARIA y departamento del lote según el mapa. |

Control: CONTROL_PP_produccion_diaria.csv, una fila por mes y unidad con DIAS, DIAS_OK (días en que la suma de lotes cuadra con el SUB TOTAL / TOTAL del PDF), DIF_MAX y ESTADO.

## 4d. Pozos, regalías, canon y precio de canasta

Salen de las mismas Estadísticas Anuales (notebook `PP_Produccion_Lotes.ipynb`, casilla «Pozos, regalías, canon y precio de canasta»). Solo se leen los anuales del período elegido: para la serie completa, correr desde 2001. **Inversión en US$ por lote: no la publica la Estadística Anual** (solo trae la inversión total del país en el resumen); los pozos perforados son el indicador de actividad disponible por lote.

**PP_pozos_perforados_lote_anio.csv** — tablas «Pozos exploratorios / confirmatorios / de desarrollo perforados por contrato» (cada anual trae 10–11 años; el de 2005 llega a 1995). Para cada año manda la **edición más reciente** (PERUPETRO corrige algunas cifras: p. ej. 2013 desarrollo = 83 en la edición 2016 y 84 en la 2020). Clave: AÑO + TIPO + LOTE + OPERADOR.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| AÑO | entero | Año de perforación (1995–hoy). |
| TIPO | texto (código) | EXPLORATORIO (busca un yacimiento nuevo), CONFIRMATORIO (delimita un descubrimiento) o DESARROLLO (produce un yacimiento conocido). Hasta 2001 (ediciones 2005 y 2008) los confirmatorios van dentro de EXPLORATORIO; desde 2002 vienen aparte. Desde 2013 no se cuentan pozos inyectores. |
| DEPARTAMENTO, OPERADOR, OPERADOR_ORIGINAL, LOTE, LOTE_HISTORICO | texto | Como en §4. Cuando un lote cambió de operador en el período, la tabla trae una fila por operador (celda de lote combinada). |
| POZOS | entero | Pozos perforados en el año. |
| FUENTE | texto | PP_ANUAL_<edición>.pdf usado para ese año. |

**PP_regalias_lote_anio.csv** — «Ingresos al fisco» / «Ingreso por regalías por contrato» de cada anual (2007–hoy, en US$) e «Ingresos por contratos» (2001–2006, en miles de US$, convertidos a US$). Clave: AÑO + MODALIDAD + HIDROCARBURO + LOTE_PDF.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| AÑO | entero | Año de las regalías. |
| MODALIDAD | texto (código) | LICENCIA (regalía) o SERVICIOS (regalía equivalente: retribución al contratista). |
| HIDROCARBURO | texto (código) | PETRÓLEO, LGN, GAS NATURAL o CONDENSADO. |
| DEPARTAMENTO, LOTE, LOTE_HISTORICO | texto | Como en §4. LOTE sin sufijos (T)/(TT). |
| LOTE_PDF | texto | Lote como figura en el PDF: distingue contratos del mismo lote (I (TT) e I.; X y X.). |
| OPERADOR | texto | Empresa que pagó: sale de la tabla de producción del mismo anual (mismo lote del PDF). «VARIOS OPERADORES» si el PDF no distingue los contratos (Lote 8 en 2024). La vista por lote suma; la vista por empresa separa. |
| REGALIA_PCT | número (%) | Porcentaje de regalía (solo edición 2007). |
| REGALIA_US$ | número (US$) | Monto del año. |

**PP_canon_departamento_anio.csv** — «Distribución del canon / sobrecanon» (series de 10 años; la edición 2001 llega a 1993). Columnas: AÑO, DEPARTAMENTO, CANON_MM_SOLES (millones de soles corrientes) y FUENTE. Para cada año manda la edición más reciente.

**PP_canon_departamento_mes.csv** y **PP_ingresos_estado_mes.csv** — del «Resumen ejecutivo» de cada estadística mensual: canon y sobrecanon por departamento (MM S/, con un mes de rezago: el reporte de enero trae los 12 meses del año anterior) e ingresos para el Estado (regalías + regalía equivalente, MM US$, total nacional por LICENCIA / SERVICIOS / TOTAL). PERUPETRO solo publica las mensuales del año en curso, así que ambas series se acumulan en Drive en cada corrida. Columnas: AÑO, MES, FECHA, DEPARTAMENTO o MODALIDAD, valor y FUENTE. Cuando hay 12 meses de canon, su suma reemplaza al anual en PP_canon_departamento_anio.csv (el valor del anual queda en

CANON_PDF_ANUAL): el anual 2025 daba 20,19 para Loreto y los meses suman 213,85.

**PP_precio_canasta_lote_mes.csv** — «Valor mensual del precio de canasta de hidrocarburos líquidos» (US$/bbl), el precio con que se calculan las regalías de cada lote. Columnas: AÑO, MES, FECHA, LOTE, VARIANTE (P = petróleo y L = líquidos del lote Z-69; LGN = líquidos de Z-2B), LOTE_PDF, PRECIO_US$_BBL y FUENTE. Cuando el PDF agrupa lotes («VII y V», «31B-31D / 31C») se repite el precio para cada uno. En 2001 el PDF da un solo precio para la zona NOROESTE.

**PP_valor_produccion_lote_mes.csv** — producción de líquidos de §4 × precio de canasta del lote y mes: BARRILES, PRECIO_US$_BBL, VALOR_US$ y ESTADO_PRECIO (OK, SIN PRECIO o SIN PRODUCCION). Para petróleo se usa la variante P y para LGN/condensado la LGN/L, si existen; si no, el precio del lote. Es un valor a precio de canasta, no el ingreso de la empresa.

**PP_contratos.csv** — cuadros «Contratos en fase de explotación / exploración» (vigentes al 31.12), «Contratos terminados» y, en 2007, «Contratos suscritos durante el año», de cada anual (2004–hoy; 2001 no se lee). Una fila por empresa socia. Se acumula en Drive por edición. Clave: EDICION + ESTADO + LOTE + EMPRESA.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| EDICION | entero | Año del anual (contratos al 31.12 de ese año). |
| ESTADO | texto (código) | VIGENTE, TERMINADO (en el año) o SUSCRITO EN EL AÑO. |
| FASE | texto (código) | EXPLOTACION o EXPLORACION (en terminados, según el bloque del cuadro). |
| DEPARTAMENTO, LOTE, LOTE_HISTORICO | texto | Como en §4. |
| OPERADOR | texto | Primera empresa listada en el contrato. |
| EMPRESA | texto | Empresa socia, como figura en el PDF. |
| PARTICIPACION_PCT | número (%) | Participación de la empresa. Vacío en ediciones antiguas, que no la traen. |
| FECHA_SUSCRIPCION, FECHA_TERMINO | fecha (dd/mm/aaaa) | Suscripción y término (o último día de vigencia). El término aparece desde la edición 2014. Puede diferir de las notas de la tabla de producción (lotes 8 y 192). |
| AREA_HA | número (ha) | Área del contrato. |
| MODALIDAD | texto (código) | LICENCIA, SERVICIOS u OPERACIONES. |
| PAGINA | entero | Página del PDF. |

**PP_operadores_lote.csv** — lo arma el notebook del mapa desde la producción fiscalizada (líquidos y gas): una fila por lote, operador y periodo continuo con producción. Columnas: DEPARTAMENTO, CAMPO, LOTE, OPERADOR, AÑO_INICIO, AÑO_FIN, AÑOS_CON_PRODUCCION, LIQUIDOS_BBL, GAS_MPC y REGALIAS_US$ (regalías de ese operador en el periodo). Un año sin producción corta el periodo.

**Control** (`CONTROL PP tablas_adicionales.csv`): una fila por tabla, edición y año con SUMA (suma de lotes o departamentos; en canasta, promedio calculado), TOTAL_PDF (total o promedio impreso), PAGINA, USADO (si esa edición es la que quedó para el año) y ESTADO. Tolerancias: pozos exacto; regalías 0,1 % (2001–2006 vienen redondeadas a miles); canon 0,05; canasta 0,011 US$/bbl. Sin promedio impreso (2007–2011) se exige el año completo. En la prueba con los anuales 2001–2025 todas las tablas cuadran, salvo dos casos reales de 2008 (lote 56, que empezó en setiembre, y XIII, al que le falta un mes en el PDF).

## 4e. Excel de canon (sección 9 del notebook)

Se bajan de las páginas «Canon y Sobre Canon» y «Canon Municipalidades» de PERUPETRO a DATA/CANON_EXCEL y se leen en cada corrida. Montos tal como los imprime el Excel (US$ o soles corrientes, con decimales). Meses: el MES es el de la producción (Determinación) o el «periodo de pago» (Distribución y Municipalidades), que es el mismo mes: enero se paga en febrero (FECHA_PAGO).

**PP_canon_lote_mes.csv** — «Canon Petrolero <año>», una hoja por mes (se ignoran hojas de trabajo como «Ene-2», «Abr (2)», «Nov-original» o «TOTAL», y los meses aún vacíos). Una fila por lote e hidrocarburo.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| AÑO, MES, FECHA | entero / fecha | Mes de producción. FECHA = 01/mm/aaaa. |
| ZONA | texto | Bloque del Excel: PIURA / TUMBES, PROVINCIA PUERTO INCA HUANUCO, LORETO / UCAYALI, CUSCO. |
| LOTE_ITEM | texto | Fila tal como figura («X-GAS», «31-C LGN (*)», «Ajustes meses anteriores (3)»). |
| LOTE, PRODUCTO | texto (código) | Lote sin el producto (Z1 → Z-1) y PETROLEO, GAS, LGN o CONDENSADO. Los ajustes van como LOTE = AJUSTES MESES ANTERIORES. |
| MODALIDAD, UNIDAD, VOLUMEN | texto / número | LICENCIA o SERVICIOS; BLS o MM BTU; volumen del mes (1ra + 2da quincena). |
| PRECIO_1Q, PRECIO_2Q_MES | número (US$/unidad) | Canasta o valor de venta de la 1ra quincena y de la 2da (o del mes). |
| DEDUCCIONES_US$ | número (US$) | Suma de flete marítimo, comercialización, oleoducto y fiscalización, como los trae el Excel. |
| VALOR_PRODUCCION_US$, CANON_TOTAL_US$ | número (US$) | Valor de la producción y canon + sobrecanon (o participación) del lote. |
| DEPARTAMENTO_1, CANON_DEP_1_US$ | texto / US$ | Primer departamento de la zona (Piura, Huánuco, Loreto, Cusco) y su parte. |
| DEPARTAMENTO_2, CANON_DEP_2_US$ | texto / US$ | Segundo departamento (Tumbes, Ucayali) y su parte; vacío si la zona tiene uno. |
| TIPO_CAMBIO, HOJA | número / texto | Tipo de cambio del Excel (0 si aún no lo tiene) y hoja de origen. |

**PP_canon_distribucion_mes.csv** — «Canon por Año <Dep.>» de Distribución: una hoja por año (1993–hoy). Columnas: DEPARTAMENTO, AÑO, MES, FECHA, FECHA_PAGO, BENEFICIARIO (como figura), TIPO_BENEFICIARIO (GOBIERNO REGIONAL, INSTITUTOS, UNIVERSIDADES, IIAP, MUNICIPALIDADES, LEY 29289), PORCENTAJE (como figura: «52% », «20% - 40%») y MONTO_SOLES. El año de la hoja manda sobre la etiqueta del mes (la hoja 2024 de Ucayali dice «Ene.2025»). Huánuco es solo la provincia de Puerto Inca.

**PP_canon_municipal_mes.csv** — dos fuentes: (1) «Canon por Año <Dep.>» de Canon Municipalidades (año en curso, 5 departamentos; Ucayali no tiene), bloque «validado con la PCM», secciones GOBIERNOS LOCALES y COMUNIDADES (5%) del D.U. 026-2010; (2) el detalle «Distribución por concejos» de la Distribución 1993–2002 (SECCION = CONCEJOS MUNICIPALES, con el % de la provincia). Columnas: DEPARTAMENTO, AÑO, MES, FECHA, FECHA_PAGO, SECCION, PROVINCIA, PORCENTAJE_PROVINCIA, MUNICIPALIDAD (sin notas «(*)»), NIVEL (PROVINCIAL o DISTRITAL: la primera de cada provincia o la marcada «(Provincial)»), MONTO_SOLES y FUENTE_EXCEL. Los meses que en el Excel aún están en 0 no se cargan. Como el Excel de Municipalidades solo trae el año en curso, la tabla se acumula en Drive (cada corrida reemplaza los meses que vuelve a leer).

**Control** (CONTROL PP canon_excel_lectura.csv): una fila por archivo, hoja, mes y parte con SUMA, TOTAL_EXCEL y ESTADO. Dentro de cada Excel: suma de lotes = «Subtotal» de la zona (US$); suma de beneficiarios = TOTAL; suma de municipalidades = TOTAL de su sección. Cruces: soles por departamento de la Determinación = total de la Distribución del mismo mes; Distribución = canon mensual y anual de los PDF (MM S/, ±0,011); municipalidades = rubro municipal de la Distribución. Tolerancia S/ 1 dentro del Excel y S/ 10 o 0,01 % en los cruces.

## 5. Control de la producción

Archivo CONTROL PP produccion_lote_mes_<ini>-<fin>.csv. Una fila por año (por archivo fuente). Es la evidencia de que los datos cuadran con el documento oficial.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| ARCHIVO | texto | PDF (o PDF y página, en los transcritos) del que salieron los datos del año. |
| TIPO | texto (código) | ANUAL, MENSUAL (acumulado del año en curso) o TRANSCRITO. |
| AÑO | entero | Año de los datos. |
| MESES | entero | Meses cubiertos (12, o menos en el año en curso). |
| LOTES | entero | Filas lote-producto leídas en la tabla del PDF. |
| FILAS_IMPUTADAS | entero | Lotes con un mes completado por diferencia (ver ESTADO_FILA). En la corrida completa: 1 (año 2021). |
| FILAS_REVISAR | entero | Lotes cuya suma de meses no coincide con su total. Debe ser 0. |
| DIF_MAX_TOTAL | número (bbl) | Máxima diferencia mensual entre la suma de los lotes y el TOTAL/SUB-TOTAL impreso en el PDF. **0 = cuadra exacto.** Es el control principal. |
| BARRILES_PETROLEO / _LGN / _CONDENSADO | número (bbl) | Total del año por producto (suma de lotes). |
| DIF_MAX_PETROLEO / _LGN / _CONDENSADO | número (bbl) | Igual que DIF_MAX_TOTAL pero contra el subtotal de cada producto. Vacío cuando el PDF no imprime subtotal por producto (anuales antiguos, 2001–2006). |
| ESTADO | texto (código) | OK; OK (transcrito); REVISAR (no cuadra); SIN TABLA; ESCANEADO / FORMATO ANTIGUO (PDF sin tabla legible, cubierto por transcripción); ERROR DE DESCARGA. |
| FECHA_EXTRACCION | texto dd/mm/aaaa | Día en que se corrió el notebook. |

## 6. Catálogo de PDF

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| URL | texto | Dirección del PDF en perupetro.com.pe. |
| ARCHIVO | texto | Nombre con que se guardó en DATA/PDF (PP_ANUAL_<año>.pdf o PP_MENSUAL_<año>_<mes>.pdf). Permite no volver a descargar lo ya guardado. |

## 7. Transcripciones 1994–2000

Archivos PP_mensual_<año>_transcrito.csv, en formato ancho (un lote por fila, un mes por columna), tal como la tabla del PDF. El notebook los convierte al formato de §4.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| ANIO | entero | Año. |
| PRODUCTO, OPERADOR, LOTE_ORIGINAL, LOTE | texto | Igual que en §4. OPERADOR conserva el nombre del PDF de esa época (p. ej. VEGSA, MPOG, PETROPERU / PLUSPETROL). |
| ENE … DIC | número (bbl) | Producción de cada mes. |
| TOTAL | número (bbl) | Total anual del lote impreso en el PDF (se verifica que sea la suma de los meses). |
| FUENTE | texto | PDF y página de la tabla (p. ej. PP_ANUAL_1995.pdf p.18). |
| fila TOTAL | — | Última fila: totales del PDF por mes, usados para validar. |

**Validación de cada año transcrito:** (1) cada lote suma su total; (2) cada mes suma el TOTAL impreso; (3) el gran total coincide con la tabla "por contratista" del mismo PDF. Las celdas que no cuadran se releen con más aumento; en 1995 se usó además un cuadro de control de la p.17 con las mismas cifras en otra tipografía.

## 8. Variables geográficas por lote

Archivo PP_LOTES_GEO.csv (notebook PP_Mapa_Lotes.ipynb). Una fila por lote. **Estado:** notebook listo y probado con datos simulados; pendiente la primera corrida con el mapa real de PERUPETRO.

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| FECHA_EXTRACCION | texto dd/mm/aaaa | Día de la corrida. |
| LOTE | texto (código) | Mismo código que en §4, para unir ambas tablas. |
| GEOMETRIA_DE | texto | Lote(s) del mapa cuyo polígono se usó. Igual a LOTE, salvo equivalencias: lote histórico (1-AB → 192; Z-69 → Z-2B), contrato temporal sin sufijo (I(T) → I) o unión de partes (31-B/D → 31-B+31-D; VII/VI → VII+VI). |
| LOTE_MAPA, CAPA, FUENTE_POLIGONO | texto | Nombre del lote en la capa (p. ej. LOTE_XCV = 95), capa y fuente del polígono. Prioridad: geoportal de PERUPETRO (contratos vigentes); los lotes antiguos sin contrato vigente salen de la capa INGEMMET de enero 2019. |
| OPERADOR_MAPA, ESTADO_MAPA, TIPO_CONTRATO, F_SUSCRIPCION | texto | Según el geoportal de PERUPETRO: operador del contrato vigente, fase (EXPLORACIÓN/EXPLOTACIÓN), tipo (LICENCIA/SERVICIOS) y fecha de suscripción. Vacíos para lotes que solo están en la capa de 2019. |
| DEPARTAMENTO | texto | Departamento con mayor parte del área del lote. |
| DEPARTAMENTO_PCT | % (0–100) | Porcentaje del área del lote en ese departamento. |
| DEPARTAMENTO_DETALLE | texto | Reparto completo, p. ej. "LORETO 67,7%; UCAYALI 32,3%". |
| DEPARTAMENTO_N | entero | Número de departamentos que toca el lote. |
| ZOCALO | SI / NO | SI para lotes mayormente en el mar (menos del 50 % de su área en tierra); se asignan al departamento costero más cercano o al de su parte en tierra. |
| CUENCA, CUENCA_PCT | texto, % | Cuenca sedimentaria (Marañón, Ucayali, Talara, ...) y % del lote en ella. |
| AREA_KM2 | número (km²) | Superficie del lote (proyección equivalente de Sudamérica, ESRI:102033). |
| LAT, LON | grados decimales | Punto interior del lote (WGS84). |
| DIST_OLEODUCTO_KM | número (km) | Distancia mínima del borde del lote al Oleoducto Norperuano; 0 si lo cruza. |
| DIST_IQUITOS_KM | número (km) | Distancia mínima del lote a Iquitos. |
| DIST_RIO_GRANDE_KM | número (km) | Distancia desde el punto interior del lote al río más cercano con caudal medio ≥ 5.000 m³/s (río troncal; HydroRIVERS, caudal modelado). Se mide desde el interior porque casi todos los lotes amazónicos tienen un río grande dentro. Aproxima el acceso fluvial; no es una medida oficial de navegabilidad. |
| DIST_RIO_1000_KM / _5000_KM / _20000_KM | número (km) | Misma distancia para afluentes (≥ 1.000 m³/s), ríos troncales (≥ 5.000) y el Amazonas o tramos bajos (≥ 20.000): sensibilidad. |
| RIO_CERCANO | texto | Nombre del río grande más cercano (ríos con nombre de OpenStreetMap que coinciden con un tramo de HydroRIVERS ≥ umbral; respaldo Natural Earth). |
| ANP_PCT, ANP_DETALLE | %, texto | Porcentaje del lote dentro de Áreas Naturales Protegidas y cuáles. |
| CCNN_DENTRO_N, CCNN_5KM_N, CCNN_DENTRO | entero, texto | Comunidades nativas dentro del lote, a menos de 5 km, y sus nombres. |
| PETROLEO_ACUM_MMBBL | número (MM bbl) | Petróleo acumulado del lote en la base de §4. |

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| CAMPO | texto | Campo al que pertenece el polígono: lotes que comparten polígono (1-AB/192; 31-B, 31-D y 31-B/D; Z-2B/Z-69…). Los indicadores de producción de esta tabla son del campo. |
| PETROLEO_ACUM_CAMPO_MMBBL | número (MM bbl) | Acumulado de todos los contratos del campo (p. ej. 1-AB + 192). |
| ESTADO_PRODUCCION … OPERADORES | varios | Indicadores de producción del campo; misma definición que en §8b. |

## 8b. Indicadores de producción por lote

Archivo PP_LOTES_INDICADORES.csv (notebook del mapa). Una fila por lote de la base de producción (§4), tenga o no polígono. Se calculan sobre todos los líquidos fiscalizados (petróleo + LGN + condensado).

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| LOTE, CAMPO, DEPARTAMENTO | texto | Lote de producción, campo al que pertenece y departamento (vacío si no tiene polígono). |
| TIENE_POLIGONO | SI / NO | Si el lote se ubicó en el mapa (directo o por equivalencia). |
| PETROLEO_ACUM_MMBBL, LIQUIDOS_ACUM_MMBBL | número (MM bbl) | Acumulado de petróleo y de todos los líquidos en la base. |
| PRODUCTO_PRINCIPAL | texto | Producto con más barriles acumulados (PETROLEO, LGN o CONDENSADO). |
| ESTADO_PRODUCCION | texto (código) | EN PRODUCCIÓN (produjo en los últimos 12 meses de la base); PARALIZADO (produjo antes y no en los últimos 12 meses); SUCEDIDO POR … (el contrato terminó y el campo siguió con otro lote, p. ej. 1-AB → 192; LOB/EA/LO → X); SIN PRODUCCIÓN REGISTRADA. |
| PRIMERA_PRODUCCION, ULTIMA_PRODUCCION | texto mm/aaaa | Primer y último mes con producción. "≤01/1994" = ya producía al inicio de la base. |
| BPD_ACTUAL | número (bpd) | Producción promedio de los últimos 12 meses de la base. |
| PICO_AÑO, PICO_BPD | entero, bpd | Año completo de mayor producción diaria y su valor. |
| DECLINACION_ANUAL_5A_PCT, DECLINACION_PERIODO | % anual, texto | Variación anual compuesta de la producción diaria en 5 años, entre dos años completos "normales" (máximo 2 meses sin producción), para que una paralización (2016, 2020) no la distorsione. Se usa el periodo más reciente que cumple (p. ej. 2019–2024). Negativo = declina; vacío si no hay dos años normales. |
| MESES_SIN_PRODUCCION | entero | Meses con 0 barriles desde la primera producción hasta el final de la base. A nivel de lote no cuentan los meses en que el campo produjo con otro contrato (p. ej. VI reportado como VII/VI). |
| PARALIZACION_MAX_MESES, PARALIZACION_MAX_DESDE | entero, mm/aaaa | Racha más larga de meses sin producción y su inicio (si llega al final de la base, sigue paralizado). |
| OPERADORES | texto | Empresas que operaron el lote con producción, con sus años, en orden: p. ej. "OCCIDENTAL (1994–2000) → PLUSPETROL (2001–2015)". |

**Fuentes del mapa:** visor "Mapa de Lotes de contrato" de PERUPETRO (ArcGIS Online); límites departamentales geoBoundaries (basados en INEI); HydroRIVERS y Natural Earth (ríos); SERNANP u OpenStreetMap (ANP); servicios públicos de comunidades nativas; oleoducto desde PERUPETRO u OpenStreetMap. **Desde el 12/10/2026** la fuente principal es el geoportal oficial de PERUPETRO (geoportal.perupetro.com.pe, servicio WFS: lotes de contrato vigentes, cuencas sedimentarias y otras capas). **Primera corrida (11/10/2026):** el servidor de PERUPETRO (gismaptemp) no responde; se usaron los lotes de enero 2019 publicados por INGEMMET, el Oleoducto Norperuano de WWF Perú, ANP y comunidades nativas de servicios públicos de ArcGIS Online (ver CONTROL PP mapa

capas.csv).

## 9. Control del mapa

| Variable | Tipo / unidad | Descripción |
|---|---|---|
| `N, CAPA, GRUPO` | texto | Número, nombre y grupo de la capa encontrada. |
| `URL, TIPO, GEOMETRIA` | texto | Servicio ArcGIS, tipo de capa y geometría (polígono, línea, punto). |
| `FUENTE, TEMA` | texto | PERUPETRO u otro servicio; tema (LOTES, ANP, CCNN, OLEODUCTO). |
| `ERROR` | texto | Motivo si la capa no respondió (p. ej. requiere inicio de sesión). |
| `ENTIDADES, ESTADO` | entero, texto | En el control de descarga: cuántos elementos llegaron y si fue OK; incluye la fila "LOTES SIN POLIGONO" con los lotes con producción sin ubicar. |

## 10. Lotes históricos y equivalencias

| Código en los datos | LOTE_HISTORICO | Explicación |
|---|---|---|
| `1-AB → 192` | 1-AB/192 | Mismo campo (Loreto). El contrato 1-AB terminó el 29/08/2015; desde el 30/08/2015 es el Lote 192. |
| `Z-2B → Z-69` | Z-2B/Z-69 | Zócalo (Piura/Tumbes). Pasó a PetroPerú como Z-69 (fecha a confirmar con el PDF de 2023). |
| `31-B, 31-D → 31-B/D` | 31-B/D | Maple: Maquía (31-B) y Agua Caliente (31-D). El PDF los separa hasta 2000 y los une desde 2001. |
| `LOB/EA/LO` | LOB/EA/LO | Lobitos, El Alto y Los Órganos (OXY/Bridas, Noroeste). Desde el 24/07/1996 se integró al Lote X, salvo los yacimientos Folche y Cruz, que pasaron al VI. Se mantiene separado. |
| `Sufijo (T)` | sin sufijo | Contrato temporal (p. ej. I(T), VI(T)): mismo lote, se agrupa con el lote base. |

## 11. Cómo usar los datos (recomendaciones)

- **Totales anuales:** sumar BARRILES por AÑO; para comparar años con distinto número de meses usar BPD promedio.
- **Series de un campo:** agrupar por LOTE_HISTORICO, no por LOTE.
- **Petróleo vs. LGN:** filtrar PRODUCTO; el LGN (Camisea desde 2004) supera al petróleo desde 2009 y distorsiona los totales de "líquidos".
- **Loreto:** filtrar DEPARTAMENTO = "LORETO" (incluye 31-B Maquía y 31-E, que el PDF ubica en Selva Central).
- **Año en curso:** es parcial; no comparar su total con años completos.
- **Operador:** es el del momento; para análisis por empresa usar OPERADOR del mes, no el actual.
- **Calidad:** antes de publicar, revisar que el CONTROL tenga ESTADO OK / OK (transcrito) en todos los años usados.

## 12. Limitaciones conocidas

- Los polígonos de lotes son de enero 2019 (INGEMMET): los lotes firmados después no tienen polígono y su DEPARTAMENTO sale de la zona.
- La fecha exacta del paso Z-2B → Z-69 está por confirmar.
- 1994–2000 provienen de escaneos: transcritos y validados al barril, pero sin capa digital original.
- Si PERUPETRO cambia el formato de sus PDF o de su página, el CONTROL lo mostrará como SIN TABLA o REVISAR (no como datos erróneos).